

# Министерство науки и высшего образования Российской Федерации Федеральное государственное бюджетное образовательное учреждение высшего образования

## «Московский государственный технический университет имени Н.Э. Баумана

(национальный исследовательский университет)» (МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ	Инфор	матика и системы управ	<u>вления</u>
КАФЕДРА	Системы о	бработки информации и	<u>управления</u>
O	тчёт по ру	бежному контрол	ю №1
		То дисциплине:	•
	«технолог	ии машинного обучения	1»
D.			
Выполнил: Студент группы И	AV5 61		Похомени К С
студент группы и	193-01	(Подпись, дата)	Пахомкин К.С. (Фамилия И.О.)
Проверил:			
			Гапанюк Ю. Е.
		(Подпись, дата)	(Фамилия И.О.)

#### Задание

Для заданного набора данных проведите обработку пропусков в данных для одного категориального и одного количественного признака. Какие способы обработки пропусков в данных для категориальных и количественных признаков Вы использовали? Какие признаки Вы будете использовать для дальнейшего построения моделей машинного обучения и почему?

#### Набор данных:

https://www.kaggle.com/san-francisco/sf-restaurant-scores-lives-standard

## РК ИУ5-61Б Пахомкин Кирсан

#### Импорт библиотек

In [4]: data.dtypes

```
In [1]: import numpy as np
         import pandas as pd
         import seaborn as sns
         import matplotlib.pyplot as plt
         from pandas.plotting import scatter matrix
         import warnings
         warnings.filterwarnings('ignore')
         sns.set(style="ticks")
         *matplotlib inline
In [2]: data = pd.read_csv('restaurant-scores-lives-standard.csv')
In [3]; data.head()
Out[3]:
           business_id business_name business_address business_city business_state business
                                      2 Marina Blvd Fort
         0
                101192
                          Cochinita #2
                                                       San Francisco
                                                                              CA
                                               Mason
                97975
                          BREADBELLY
                                      1408 Clement St San Francisco
                                                                              CA
                            Great Gold
                92982
         2
                                          3161 24th St. San Francisco
                                                                              CA
                            Restaurant
                                        214 CALIFORNIA
                101389
                            HOMAGE
                                                       San Francisco
                                                                              CA
                85986
                          Pronto Pizza
                                           798 Eddy St San Francisco
                                                                              CA
        5 rows × 23 columns
```

```
int64
Out[4]: business_id
        business_name
                                    object
        business address
                                    object
        business_city
                                    object
        business state
                                    object
        business postal code
                                    object
                                   float64
        business_latitude
        business_longitude
                                   float64
        business_location
                                    object
        business_phone_number
                                  float64
        inspection id
                                    object
        inspection date
                                    object
        inspection_score
                                  float64
        inspection_type
                                    object
        violation_id
                                    object
        violation_description
                                    object
        risk category
                                   object
float64
        Neighborhoods (old)
        Police Districts
                                   float64
                                    float64
        Supervisor Districts
        Fire Prevention Districts
                                   float64
        Zip Codes
                                   float64
        Analysis Neighborhoods
                                   float64
        dtype: object
In [5]: data.isnull().sum()
        # проверим есть ли пропущенные значения
Out[5]: business_id
       business name
                                        0
        business_address
        business_city
                                        0
        business state
                                       0
                                    1018
        business_postal_code
        business latitude
                                   19556
        business longitude
                                   19556
                                  19556
        business_location
        business_phone_number
                                   36938
        inspection_id
                                       0
        inspection_date
                                        0
       inspection_score
inspection_type
                                  13610
                                       0
        violation_id
                                   12870
        violation description
                                   12870
        risk_category
                                   12870
        Neighborhoods (old)
                                   19594
        Police Districts
                                    19594
        Supervisor Districts
                                   19594
        Fire Prevention Districts
                                   19646
        Zip Codes
                                    19576
        Analysis Neighborhoods
                                   19594
```

dtype: int64

In [6]: data.info()

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 53973 entries, 0 to 53972
Data columns (total 23 columns):
```

# Column		Non-Null Count	Dtype	
0	business_id	53973 non-null	int64	
1	business_name	53973 non-null	object	
2	business_address	53973 non-null	object	
3	business_city	53973 non-null	object	
4	business_state	53973 non-null	object	
5	business_postal_code	52955 non-null	object	
6	business latitude	34417 non-null	float64	
7	business longitude	34417 non-null	float64	
8	business_location	34417 non-null	object	
9	business phone number	17035 non-null	float64	
10	inspection_id	53973 non-null	object	
11	inspection_date	53973 non-null	object	
12	inspection score	40363 non-null	float64	
13	inspection type	53973 non-null	object	
14	violation id	41103 non-null	object	
15	violation_description	41103 non-null	object	
16	risk_category	41103 non-null	object	
17	Neighborhoods (old)	34379 non-null	float64	
18	Police Districts	34379 non-null	float64	
19	Supervisor Districts	34379 non-null	float64	
20	Fire Prevention Districts	34327 non-null	float64	
21	Zip Codes	34397 non-null	float64	
22	Analysis Neighborhoods	34379 non-null	float64	
	es: float64(10), int64(1), ry usage: 9.5+ MB	object(12)		

### Обработка пропусков

```
In [7]: # Удаляем столбцы, которые не несут значимой информации data.drop(['business_name','business_address'], axis = 1, inplace = True)

In [8]: data.info()
```

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 53973 entries, 0 to 53972
Data columns (total 21 columns):

#	Column	Non-Null Count	Dtype
0	business_id	53973 non-null	int64
1	business city	53973 non-null	object
2	business state	53973 non-null	object
3	business_postal_code	52955 non-null	object
4	business latitude	34417 non-null	float64
5	business_longitude	34417 non-null	float64
6	business_location	34417 non-null	object
7	business_phone_number	17035 non-null	float64
8	inspection_id	53973 non-null	object
9	inspection_date	53973 non-null	object
10	inspection_score	40363 non-null	float64
11	inspection_type	53973 non-null	object
12	violation_id	41103 non-null	object
13	violation_description	41103 non-null	object
14	risk_category	41103 non-null	object
15	Neighborhoods (old)	34379 non-null	float64
16	Police Districts	34379 non-null	float64
17	Supervisor Districts	34379 non-null	float64
18	Fire Prevention Districts	34327 non-null	float64
19	Zip Codes	34397 non-null	float64
20	Analysis Neighborhoods	34379 non-null	float64
	es: float64(10), int64(1), ry usage: 8.6+ MB	object(10)	

#### Обработка пропусков в числовых данных

```
In [9]: # Заполняем отсутствующие значения
data['business_latitude'] = data['business_latitude'].replace(0,np.nan)
data['business_latitude'] = data['business_latitude'].fillna(data['business
In [10]: data.head()
```

Out[10]:

	business_id	business_city	business_state	business_postal_code	business_latitude	bu
0	101192	San Francisco	CA	NaN	37.771619	
1	97975	San Francisco	CA	94118	37.771619	
2	92982	San Francisco	CA	94110	37.771619	
3	101389	San Francisco	CA	94111	37.771619	
4	85986	San Francisco	CA	94109	37.771619	

5 rows x 21 columns

```
In [11]: data.isnull().sum()
# проверим есть ли пропущенные значения в столбце business_latitude
```

```
Dut[11]: business_id
                                        0
         business city
                                        0
         business state
                                        0
         business_postal_code
                                     1018
         business latitude
                                        0
        business_longitude
                                   19556
         business_location
                                    19556
         business_phone_number
                                    36938
         inspection_id
                                        0
         inspection_date
                                        0
         inspection score
                                   13610
         inspection_type
                                        0
         violation id
                                   12870
         violation_description
                                    12870
                                    12870
         risk_category
         Neighborhoods (old)
                                    19594
         Police Districts
                                    19594
         Supervisor Districts
                                    19594
         Fire Prevention Districts
                                  19646
         Zip Codes
                                    19576
         Analysis Neighborhoods
                                    19594
         dtype: int64
```

In [14]: # Заполняем отсутствующие значения

data.head()

data['violation\_id'] = data.fillna("Name")

#### Обработка пропусков в категориальных данных

```
In [12]: total_count = data.shape[0]
         print('BCEFO CTPOK: {}'.format(total_count))
         Всего строк: 53973
In [13]: # Выберем категориальные колонки с пропущенными значениями
          # Цикл по колонкам датасета
          cat cols = []
          for col in data.columns:
              # Количество пустых значений
              temp_null_count = data[data[col].isnull()].shape[0]
             dt = str(data[col].dtype)
             if temp_null_count>0 and (dt=='object'):
                  cat_cols.append(col)
                  temp_perc = round((temp_null_count / total_count) * 100.0, 2)
                  print('Колонка {}. Тип данных {}. Количество пустых значений {}, {
         Колонка business postal code. Тип данных object. Количество пустых значений
         1018, 1.89%.
         Колонка business_location. Тип данных object. Количество пустых значений 19
         556, 36.23%.
         Колонка violation id. Тип данных object. Количество пустых значений 12870,
         23.85%.
         Колонка violation description. Тип данных object. Количество пустых значени
         й 12870, 23.85%.
         Колонка risk_category. Тип данных object. Количество пустых значений 12870,
         23.85%.
```

	business_id	business_city	business_state	business_postal_code	business_latitude bu
0	101192	San Francisco	CA	NaN	37.771619
1	97975	San Francisco	CA	94118	37.771619
2	92982	San Francisco	CA	94110	37.771619
3	101389	San Francisco	CA	94111	37.771619

CA

94109

37,771619

#### 5 rows x 21 columns

85986 San Francisco

In [15]: data.isnull().sum() # проверим есть ли пропущенные значения в столбце violation\_id

Out[15]: business\_id business\_city 0 business\_state 0 business\_postal\_code business\_latitude 1018 0 19556 business\_longitude business\_location business\_phone\_number 19556 36938 inspection\_id inspection\_date 0 inspection\_score 13610 inspection\_type 0 0 violation\_id 12870 violation description risk\_category 12870 Neighborhoods (old) 19594 Police Districts 19594 Supervisor Districts 19594 Fire Prevention Districts 19646 Zip Codes 19576 Analysis Neighborhoods 19594 dtype: int64