Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ Информатика и системы управления

КАФЕДРА Системы обработки информации и управления

Отчёт по рубежному контролю №2

По дисциплине:
«Технологии машинного обучения»

Выполнил:

Студент группы ИУ5-61Б _____ **Пахомкин К. С.**

(Подпись, дата) (Фамилия И.О.)

Проверил:

_____ **Гапанюк Ю. Е.**

(Подпись, дата) (Фамилия И.О.)

Москва, 2021

Задание.

Для заданного набора данных (по Вашему варианту) постройте модели классификации или регрессии (в зависимости от конкретной задачи, рассматриваемой в наборе данных). Для построения моделей используйте методы 1 и 2 (по варианту для Вашей группы). Оцените качество моделей на основе подходящих метрик качества (не менее двух метрик). Какие метрики качества Вы использовали и почему? Какие выводы Вы можете сделать о качестве построенных моделей? Для построения моделей необходимо выполнить требуемую предобработку данных: заполнение пропусков, кодирование категориальных признаков, и т.д.

Для студентов групп ИУ5-61Б, ИУ5-62Б, ИУ5-63Б, ИУ5-64Б, ИУ5-65Б, РТ5-61Б номер варианта = номер в списке группы.

Набор данных:

https://www.kaggle.com/noriuk/us-education-datasets-unification-projec

РК ИУ5-61Б Пахомкин Кирсан

Импорт библиотек

In [1]:
```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from pandas.plotting import scatter_matrix
import warnings
warnings.filterwarnings('ignore')
sns.set(style="ticks")
%matplotlib inline
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder
```

In [2]:
```
data = pd.read_csv('states_all_extended.csv')
```

In [3]:
```
data.head()
```

Out[3]:

	PRIMARY_KEY	STATE	YEAR	ENROLL	TOTAL_REVENUE	FEDERAL_REVENUE	ST
0	1992_ALABAMA	ALABAMA	1992	NaN	2678885.0	304177.0	
1	1992_ALASKA	ALASKA	1992	NaN	1049591.0	106780.0	
2	1992_ARIZONA	ARIZONA	1992	NaN	3258079.0	297888.0	
3	1992_ARKANSAS	ARKANSAS	1992	NaN	1711959.0	178571.0	
4	1992_CALIFORNIA	CALIFORNIA	1992	NaN	26260025.0	2072470.0	

5 rows × 266 columns

In [4]:
```
parts = np.split(data, [10], axis=1)
data = parts[0]
```

In [5]:
```
data.dtypes
```

Out[5]:
```
PRIMARY_KEY                object
STATE                      object
YEAR                       object
ENROLL                     object
TOTAL_REVENUE              object
FEDERAL_REVENUE            object
STATE_REVENUE              object
LOCAL_REVENUE              object
TOTAL_EXPENDITURE          object
INSTRUCTION_EXPENDITURE    object
dtype: object
```

In [6]:
```
data.drop(['ENROLL','PRIMARY_KEY'], axis = 1, inplace = True)
```

In [7]:
```
le = LabelEncoder()
le.fit(data.STATE.drop_duplicates())
data.STATE = le.transform(data.STATE)
```

In [8]:
```
data['YEAR'] = data['YEAR'].replace(0,np.nan)
data['YEAR'] = data['YEAR'].fillna(data['YEAR'].mean())
data['TOTAL_REVENUE'] = data['TOTAL_REVENUE'].replace(0,np.nan)
data['TOTAL_REVENUE'] = data['TOTAL_REVENUE'].fillna(data['TOTAL_REVENUE'].
data['FEDERAL_REVENUE'] = data['FEDERAL_REVENUE'].replace(0,np.nan)
data['FEDERAL_REVENUE'] = data['FEDERAL_REVENUE'].fillna(data['FEDERAL_REVE
data['STATE_REVENUE'] = data['STATE_REVENUE'].replace(0,np.nan)
data['STATE_REVENUE'] = data['STATE_REVENUE'].fillna(data['STATE_REVENUE'].
data['LOCAL_REVENUE'] = data['LOCAL_REVENUE'].replace(0,np.nan)
data['LOCAL_REVENUE'] = data['LOCAL_REVENUE'].fillna(data['LOCAL_REVENUE'].
data['TOTAL_EXPENDITURE'] = data['TOTAL_EXPENDITURE'].replace(0,np.nan)
data['TOTAL_EXPENDITURE'] = data['TOTAL_EXPENDITURE'].fillna(data['TOTAL_EX
data['TOTAL_REVENUE'] = data['TOTAL_REVENUE'].replace(0,np.nan)
data['INSTRUCTION_EXPENDITURE'] = data['INSTRUCTION_EXPENDITURE'].fillna(da
```

In [9]:
```
data.isnull().sum()
# проверим есть ли пропущенные значения
```

Out[9]:
```
STATE                       0
YEAR                        0
TOTAL_REVENUE               0
FEDERAL_REVENUE             0
STATE_REVENUE               0
LOCAL_REVENUE               0
TOTAL_EXPENDITURE           0
INSTRUCTION_EXPENDITURE     0
dtype: int64
```

In [10]:
```
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1715 entries, 0 to 1714
Data columns (total 8 columns):
 #   Column                  Non-Null Count  Dtype
---  ------                  --------------  -----
 0   STATE                   1715 non-null   int64
 1   YEAR                    1715 non-null   int64
 2   TOTAL_REVENUE           1715 non-null   float64
 3   FEDERAL_REVENUE         1715 non-null   float64
 4   STATE_REVENUE           1715 non-null   float64
 5   LOCAL_REVENUE           1715 non-null   float64
 6   TOTAL_EXPENDITURE       1715 non-null   float64
 7   INSTRUCTION_EXPENDITURE 1715 non-null   float64
dtypes: float64(6), int64(2)
memory usage: 107.3 KB
```

In [11]:
```
data.head()
```

Out[11]:

	STATE	YEAR	TOTAL_REVENUE	FEDERAL_REVENUE	STATE_REVENUE	LOCAL_REVENUE
0	0	1992	2678885.0	304177.0	1659028.0	715680.0
1	1	1992	1049591.0	106780.0	720711.0	222100.0
2	2	1992	3258079.0	297888.0	1369815.0	1590376.0
3	3	1992	1711959.0	178571.0	958785.0	574603.0
4	4	1992	26260025.0	2072470.0	16546514.0	7641041.0

In [12]:
```
#Построим корреляционную матрицу
fig, ax = plt.subplots(figsize=(15,7))
sns.heatmap(data.corr(method='pearson'), ax=ax, annot=True, fmt='.2f')
```

Out[12]: <AxesSubplot:>

In [13]:
```
X = data.drop(['TOTAL_EXPENDITURE'], axis = 1)
Y = data.TOTAL_EXPENDITURE
print('Входные данные:\n\n', X.head(), '\n\nВыходные данные:\n\n', Y.head(
```

Входные данные:

```
    STATE  YEAR  TOTAL_REVENUE  FEDERAL_REVENUE  STATE_REVENUE  LOCAL_REVEN
UE  \
0       0  1992      2678885.0         304177.0      1659028.0       715680.
0
1       1  1992      1049591.0         106780.0       720711.0       222100.
0
2       2  1992      3258079.0         297888.0      1369815.0      1590376.
0
3       3  1992      1711959.0         178571.0       958785.0       574603.
0
4       4  1992     26260025.0        2072470.0     16546514.0      7641041.
0

   INSTRUCTION_EXPENDITURE
0                1481703.0
1                 498362.0
2                1435908.0
3                 964323.0
4               14358922.0
```

Выходные данные:

```
 0     2653798.0
1      972488.0
2     3401580.0
3     1743022.0
4    27138832.0
Name: TOTAL_EXPENDITURE, dtype: float64
```

In [14]:
```
X_train,  X_test,  Y_train,  Y_test = train_test_split(X,  Y, random_state
print('Входные параметры обучающей выборки:\n\n',X_train.head(), \
      '\n\nВходные параметры тестовой выборки:\n\n', X_test.head(), \
      '\n\nВыходные параметры обучающей выборки:\n\n', Y_train.head(), \
      '\n\nВыходные параметры тестовой выборки:\n\n', Y_test.head())
```

Входные параметры обучающей выборки:

```
       STATE  YEAR  TOTAL_REVENUE  FEDERAL_REVENUE  STATE_REVENUE  \
82        33  1993   1.217194e+06    154018.000000   8.977250e+05
1579      45  1989   9.102045e+06    767779.864314   4.308218e+06
1544      40  1989   9.102045e+06    767779.864314   4.308218e+06
1323       6  2017   9.102045e+06    767779.864314   4.308218e+06
249       47  1996   9.652380e+05     36693.000000   2.156570e+05

      LOCAL_REVENUE  INSTRUCTION_EXPENDITURE
82     1.654510e+05             5.877530e+05
1579   4.110522e+06             4.768010e+06
1544   4.110522e+06             4.768010e+06
1323   4.110522e+06             4.768010e+06
249    7.128880e+05             4.245620e+05
```

Входные параметры тестовой выборки:

```
       STATE  YEAR  TOTAL_REVENUE  FEDERAL_REVENUE  STATE_REVENUE  \
1101      32  2013   2.807010e+07     1.145079e+06   1.098613e+07
6          6  1992   3.834302e+06     1.435420e+05   2.342539e+06
746       34  2006   4.701879e+07     3.340216e+06   2.018352e+07
1320       6  1989   9.102045e+06     7.677799e+05   4.308218e+06
473       15  2001   9.124748e+06     4.448610e+05   4.590018e+06

      LOCAL_REVENUE  INSTRUCTION_EXPENDITURE
1101   1.593888e+07             1.548994e+07
6      2.348221e+06             2.148041e+06
746    2.349506e+07             2.958952e+07
1320   4.110522e+06             4.768010e+06
473    4.089869e+06             4.364661e+06
```

Выходные параметры обучающей выборки:

```
 82      1.223185e+06
1579    9.206242e+06
1544    9.206242e+06
1323    9.206242e+06
249     9.758170e+05
Name: TOTAL_EXPENDITURE, dtype: float64
```

Выходные параметры тестовой выборки:

```
 1101    2.817990e+07
6       3.721338e+06
746     4.835977e+07
1320    9.206242e+06
473     8.991877e+06
Name: TOTAL_EXPENDITURE, dtype: float64
```

In [15]:
```
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_absolute_error, mean_squared_error,  media
```

In [16]:
```
Lin_Reg = LinearRegression().fit(X_train, Y_train)

lr_y_pred = Lin_Reg.predict(X_test)
```

In [17]:
```
plt.scatter(X_test.YEAR, Y_test,    marker = 's', label = 'Тестовая выборка
plt.scatter(X_test.YEAR, lr_y_pred, marker = '.', label = 'Предсказанные да
plt.legend (loc = 'lower right')
plt.xlabel ('INSTRUCTION_EXPENDITURE')
plt.ylabel ('TOTAL_EXPENDITURE')
plt.show()
```

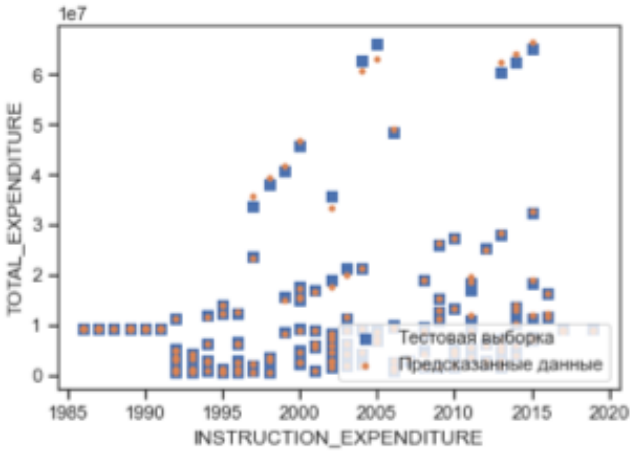

In [18]:
```
from sklearn.ensemble import RandomForestRegressor
```

In [19]:
```
forest_1 = RandomForestRegressor(n_estimators=5, oob_score=True, random_sta
forest_1.fit(X, Y)
```

Out[19]:
```
RandomForestRegressor(n_estimators=5, oob_score=True, random_state=10)
```

In [20]:
```
Y_predict = forest_1.predict(X_test)
print('Средняя абсолютная ошибка:',    mean_absolute_error(Y_test, Y_predict
print('Средняя квадратичная ошибка:', mean_squared_error(Y_test, Y_predict
print('Median absolute error:',       median_absolute_error(Y_test, Y_predi
print('Коэффициент детерминации:',    r2_score(Y_test, Y_predict))
```

```
Средняя абсолютная ошибка: 138734.77325582213
Средняя квадратичная ошибка: 142889066665.99045
Median absolute error: 19317.29999999993
Коэффициент детерминации: 0.9990572084607852
```

In [21]:
```
plt.scatter(X_test.YEAR, Y_test,    marker = 'o', label = 'Тестовая выборка
plt.scatter(X_test.YEAR, Y_predict, marker = '.', label = 'Предсказанные да
plt.legend(loc = 'lower right')
plt.xlabel('INSTRUCTION_EXPENDITURE')
plt.ylabel('INSTRUCTION_EXPENDITURE')
plt.show()
```

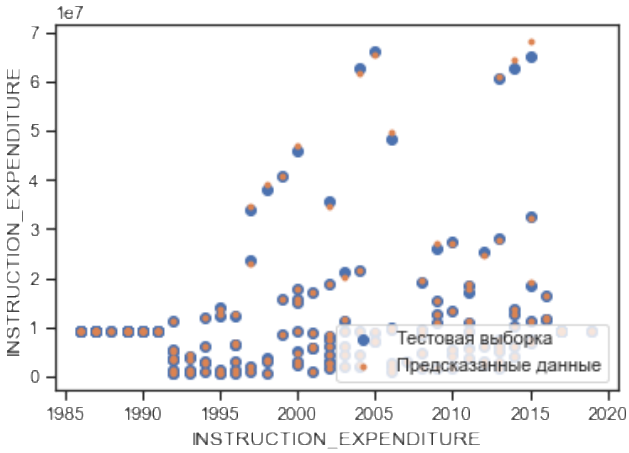
1e7
7
6
5
4
3
2
1
0
INSTRUCTION_EXPENDITURE
1985
1990
1995
2000
2005
2010
2015
2020
INSTRUCTION_EXPENDITURE
Тестовая выборка
Предсказанные данные